

Plataforma hardware y software para el desarrollo y validación de algoritmos de control de actitud para cuadricópteros

Miguel Fernández Cortizas

Índice general

1	Introducción	2
1.1	Motivación	2
1.2	Solución propuesta	3
1.3	Objetivos	4
2	Estado del arte	5
2.1	Plataformas de control de cuadricópteros	5
2.2	Aprendizaje por refuerzo	5
3	Fundamentos teóricos	6
3.1	Control clásico	6
3.1.1	Controlador PID	6
3.2	Redes neuronales artificiales	6
3.3	Aprendizaje por refuerzo	8
3.3.1	DQN	9
3.3.2	DDPG	9
3.3.3	TRPO	9
3.3.4	PPO	9
4	Hardware	10
4.1	Cuadro	10
4.2	Motores y hélices	11
4.3	Variadores (ESC)	11
4.4	Baterías	12
4.5	Autopiloto	13
4.5.1	Fase de Potencia	14
4.5.2	El microcontrolador (ESP32)	15
4.5.3	Sensores	15
4.6	Banco de pruebas	16
5	Software	18
5.1	Software del Autopiloto	18
5.1.1	Estimación del Estado	18
5.1.2	Interfaz WiFi	18
5.1.3	Generación de comandos <i>on-board</i>	19
5.2	Software de la estación	19
5.2.1	Entorno de simulación	19
5.2.2	Agente (generación de comandos)	21
5.2.3	Interfaz Estación-Autopiloto	21

5.3	Descripción del equipo	21
6	Metodología (Problem Formulation)	22
6.1	Diseño del estado	22
6.2	Diseño de las acciones	22
6.3	Diseño de la función de recompensa	23
7	Experimentos	24
8	Discusión	25
9	Conclusiones y trabajo futuro	1

Resumen

hola

Introducción

Un multirrotor es un vehículo aéreo no tripulado o UAV (por sus siglas en inglés *Unmanned Aerial Vehicles*) cuyos motores y hélices están orientadas de forma vertical.

Estas aeronaves son mucho más maniobrables que una aeronave de ala fija, ya que, al poder mantenerse estables en una posición fija pueden realizar trayectorias de forma más precisa en espacios reducidos. Comparado con un helicóptero, el cual también puede mantenerse estable en un punto fijo, los multirrotores cuentan con un mantenimiento mucho más sencillo debido a la ausencia de complejos mecanismos.

Generalmente los motores de estas aeronaves son eléctricos, ya que poseen una gran velocidad de reacción y son capaces de manejar una gran cantidad de energía con rendimientos muy elevados. La energía que requieren se proporciona a través de baterías, lo cual limita el tiempo de vuelo de estas aeronaves, cuya autonomía es significativamente inferior a la de las aeronaves de ala fija o a la de los helicópteros con motores de combustión.

Todo esto, unido a su reducido precio, ha permitido que se potencie el uso masivo de este tipo de aeronaves para labores de: agricultura de precisión, topografía, inspección industrial y rodajes cinematográficos, entre otros usos.

Existen diversas topologías asociadas a los multirrotores, dependiendo del número de motores y la disposición de éstos. En este trabajo vamos a trabajar con un cuadricóptero o cuadirrotor (cuenta con cuatro motores) con disposición en X (fig. 1.1).




Figura 1.1: Esquema cuadirrotor en X

Se ha escogido esta topología de multirrotor debido a que posee el mínimo número de motores que permiten un modelo sencillo de la dinámica de la aeronave.

1.1. Motivación

La popularidad de estas aeronaves en ámbitos como la inspección, la topografía o el ámbito cinematográfico requieren que la nave sea muy estable y que se pueda manejar con precisión. Todas estas aeronaves cuentan con un sistema electrónico que se encarga de

que la nave sea estable y que facilite el pilotaje de la misma. A este sistema se le conoce como la controladora de vuelo o autopiloto.



Figura 1.2: Autopiloto comercial Pixhawk 4

Actualmente, los autopilotos emplean algoritmos de control clásicos, basados la gran mayoría en reguladores PID para asegurar la estabilidad de la aeronave y permitir que se pilote de forma precisa. Debido a la peligrosidad de los drones (hélices afiladas girando a miles de revoluciones por minuto) no se pueden probar nuevos algoritmos de control sin tener sujeto al cuadricóptero.

Las teoría clásica de control empleada para estabilizar un cuadirrotor requiere de un fino ajuste de los parámetros del modelo. Los últimos avances en aprendizaje automático han permitido que se desarrollen nuevos algoritmos de control empleando técnicas de aprendizaje por refuerzo y redes neuronales.

1.2. Solución propuesta

Con el objetivo de poder desarrollar nuevos algoritmos para el control de cuadirrotores se ha desarrollado una plataforma, tanto hardware como software, que permita diseñar y probar estos algoritmos de forma segura. Esta plataforma esta constituida de :

- **Entorno de simulación**, sobre el que se puedan probar los algoritmos de control en una aeronave simulada.
- **Cuadirrotor con autopiloto de diseño propio**, será la aeronave donde se probarán los algoritmos diseñados. Al contar con una controladora de vuelo de diseño propio se pueden implementar los distintos algoritmos de control a bordo.
- **Interfaz con el autopiloto**, el cual comunica a la aeronave con un ordenador, el cual puede enviar comandos a la aeronave y recibir el estado de la misma. Esto permite la implementación de algoritmos *en tierra*, en los cuales la computación del algoritmo se realiza en un ordenador en vez de en el microcontrolador del autopiloto.
- **Banco de pruebas**, con distintas configuraciones en función del experimento que se desee realizar. Este banco permitirá probar los algoritmos de control de forma segura.

Adicionalmente, se ha probado el rendimiento de distintos algoritmos de control basados en técnicas de aprendizaje por refuerzo para poder compararlos con los algoritmos de control clásicos PID.

1.3. Objetivos

Para poder llevar a cabo esta plataforma y poder implementar algún algoritmo basado en aprendizaje por refuerzo es necesario desglosar los objetivos principales en tareas de alcance más reducido:

■ Entorno de simulación:

- Estudio del estado del arte acerca de entornos de simulación para el diseño de algoritmos de control para cuadricópteros.
- Estudio del estado del arte acerca de las técnicas de aprendizaje por refuerzo y el control de drones.
- Adaptación del entorno de simulación a la plataforma escogida e integración con ROS.
- Implementación de algoritmos clásicos en el entorno de simulación.
- Diseño de nuevos algoritmos de control basados en aprendizaje por refuerzo y entrenamiento de los mismos.
- Comparativa de los algoritmos en simulación.

■ Cuadrirrotor con autopiloto de diseño propio:

- Estudio del estado del arte acerca de los autopilotos comerciales.
- Diseño y construcción completa del autopiloto: componentes, placa de circuito impreso y soldadura de componentes.
- Programación del *firmware* del autopiloto.
- Diseño CAD de los componentes mecánicos del cuadrirrotor e impresión 3D de los mismos.
- Montaje y ensamblaje de todos los componentes de la aeronave.

■ Interfaz con el autopiloto:

- Diseño del protocolo de comunicación WiFi
- Integración del protocolo con ROS y con el autopiloto.

■ Banco de pruebas:

- Diseño CAD de las piezas de los distintos bancos de pruebas e impresión 3D de las mismas.

■ Experimentación de los algoritmos en el mundo real: [reducir o ampliar con los experimentos disponibles](#)

- Implementación a bordo de los algoritmos clásicos.
- Implementación externa de los algoritmos clásicos.
- Implementación externa de los algoritmos basados en técnicas de aprendizaje por refuerzo.

Estado del arte

2.1. Plataformas de control de cuadricópteros

2.2. Aprendizaje por refuerzo

La teoría clásica de control empleada para estabilizar un cuadricóptero requiere un fino ajuste de los parámetros del modelo. Los últimos avances en aprendizaje automático han permitido que se desarrollen nuevos algoritmos de control empleando técnicas de aprendizaje por refuerzo y redes neuronales.

En 2004, HJ Kim et al. [1] emplearon algoritmos de *reinforcement learning* para estabilizar (*hover*) un helicóptero y conseguir realizar maniobras acrobáticas. En 2006 Andrew Y. et al [2] siguieron con esta investigación consiguiendo que el helicóptero se estabilizara al revés (*inverted hover*). En 2010 Travis Dierks et al. [3] desarrollaron un controlador no lineal, basado en redes neuronales, para estabilizar un cuadricóptero y seguir trayectorias.

Unos años después, en 2017 Jemin Hwangbo et al. [4] desarrollaron un método para controlar un quadricóptero con una red neuronal usando técnicas de *reinforcement learning*. En 2018 William Koch et al. [5] desarrollaron un entorno de simulación, GYMFC, para el desarrollo de sistemas de control empleando RL.

Fundamentos teóricos

3.1. Control clásico

Existe una gran cantidad de controladores clásicos que se pueden emplear para generar estos comandos, por ejemplo: PID o LQR. En este trabajo se han explorado 2 controladores: el primero de ellos se trata de un controlador clásico PID y el segundo consiste en un controlador no lineal modelizado por una red neuronal.

3.1.1. Controlador PID

El controlador PID es un método de control clásico basado en generar una salida A_t basada en el error e_t , es decir, la diferencia entre el estado deseado S_{ref} y el estado actual S_t .

$$e_t = S_{ref} - S_t \quad (3.1)$$

La salida del controlador PID se contruye sumando la contribución de 3 términos:

1. **Parte proporcional (P)** La parte proporcional, como su propio nombre indica, crece de forma proporcional con el error e_t , según la constante de proporcionalidad K_p

$$P_{out} = K_p \cdot e_t \quad (3.2)$$

2. **Parte integral (I)** La parte integral

3.2. Redes neuronales artificiales

Una red neuronal artificial (ANN) esta compuesta por un conjunto de nodos o perceptrones interconectados entre sí. Estos perceptrones se agrupan en capas “ocultas”, se les atribuye este nombre debido a que todos los nodos de una capa se interconectan con todos los nodos de la capa anterior, por lo que después del aprendizaje de la red no se sabe cuales son los perceptrones de la capa anterior que influyen en un nodo.

[imagen](#)

Cada perceptron es la unidad mínima de computación de una ANN, estas unidades se dividen en dos partes, una parte lineal y una parte de activación o no lineal. En la parte

lineal o parte “Z” se computa una regresión lineal de las salidas de los nodos anteriores.

$$z_i^{[l]} = \sum_{j=0}^{n^{[l-1]}} w_{ij} \cdot a_j^{[l-1]} + b_i \quad i = 0, \dots, n^{[l]} \quad (3.3)$$

$$a_i^{[l]} = g\left(z_i^{[l]}\right) \quad i = 0, \dots, n^{[l]} \quad (3.4)$$

El superíndice $[l]$ hace referencia a la capa en la que se encuentra el elemento. Siendo $n^{[l]}$ el número de nodos de la capa l -ésima.

A los coeficientes w_{ij} se les denomina los pesos del perceptrón y b_i es el término independiente de la regresión.

La función $g(z)$ es la función de activación del nodo. Estas funciones proporcionan no linealidad a la red neuronal, permitiendo a estas la capacidad de generar modelos con grandes no linealidades. Las funciones de activación más frecuentes en la literatura son:

- Función sigmoide:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad \sigma(z) : \mathbb{R} \rightarrow [0, 1] \quad (3.5)$$

- Tangente hiperbólica:

$$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}} \quad \tanh(z) : \mathbb{R} \rightarrow [-1, 1] \quad (3.6)$$

- ReLu (del inglés *Rectified Linear Unit*):

$$g(z) = \max(0, z) \quad g(z) : \mathbb{R} \rightarrow [0, +\infty] \quad (3.7)$$

Para conseguir que la red neuronal realice predicciones precisas es necesario ajustar los pesos de la red, a este proceso es al que se denomina entrenamiento o aprendizaje. En el paradigma del aprendizaje supervisado este entrenamiento se realiza sometiendo a la red a ejemplos cuya salida es conocida. El objetivo de la red es minimizar la diferencia de su salida con la salida real del ejemplo. Formalmente, se define una función de coste \mathcal{J} la cual se quiere minimizar. Por ejemplo, una función de coste típica para problemas de clasificación binaria es:

$$\mathcal{L}(\hat{y}, y) = -(y \log \hat{y} + (1 - y) \log(1 - \hat{y})) \quad (3.8)$$

$$\mathcal{J}(w, b) = \frac{1}{m} \sum_{i=1}^m \mathcal{L}(\hat{y}^{(i)}, y^{(i)}) \quad (3.9)$$

donde \hat{y} denota la estimación de la salida realizada por parte de la red, y la salida conocida y m el número de ejemplos.

Para minimizar esta función de coste, que depende de los pesos de la red, existen distintos métodos, uno de los más usados es el método del descenso de gradiente. Este método emplea la “propagación hacia atrás” (del inglés *back propagation*) de la red neuronal, esto consiste en obtener las derivadas parciales de la función de coste con respecto a los pesos de cada nodo y actualizar estos pesos en la dirección opuesta al máximo gradiente.

$$w := w - \alpha \frac{\partial \mathcal{J}(w, b)}{\partial w} \quad (3.10)$$

$$b := b - \alpha \frac{\partial \mathcal{J}(w, b)}{\partial b} \quad (3.11)$$

donde α denota la tasa de aprendizaje, es decir, lo rápido que varían estos pesos.

3.3. Aprendizaje por refuerzo

El aprendizaje por refuerzo o *Reinforcement learning* [6] es un área del aprendizaje automático o *Machine Learning* en el que un agente interactúa con un entorno buscando la mejor acción a realizar en función de su estado actual.

Se diferencia de otras técnicas de aprendizaje automático es su enfoque orientado a la interacción directa con el entorno, sin basarse en un modelo completo del entorno o en un conjunto de ejemplos supervisados.

Elementos del aprendizaje por refuerzo

Además del agente y el entorno se pueden identificar tres elementos principales más en un sistema de aprendizaje con refuerzo:

- **Política** (Proveniente del término anglosajón *policy*, el cual es el término empleado en el estado del arte). Define el conjunto de acciones que debe realizar el agente para conseguir maximizar su recompensa en función su estado, el cuál es percibido a través del entorno. La *policy* constituye el núcleo del agente y nos permite determinar su comportamiento. Estas políticas pueden ser estocásticas.
- **Recompensa**. Define el objetivo del agente en un problema de aprendizaje por refuerzo. En cada salto de tiempo (*step*) el agente recibe una recompensa por parte del entorno (un número).
- **Función de valor**. Representa la máxima recompensa que puede esperar obtener un agente desde un estado concreto, es decir, tiene en cuenta la recompensa a largo plazo, no solo la inmediata.

Algunos algoritmos de aprendizaje por refuerzo requieren de la definición de un **modelo del entorno**. Este modelo permite predecir el comportamiento que va a tener el entorno a lo largo del tiempo.

Procesos de decisión de Markov

El aprendizaje por refuerzo emplea el marco formal de los procesos de decisión de Markov (*MDP*) en los cuales para definir la interacción entre el agente y el entorno en términos de estados, acciones y recompensas.

Un proceso de decisión de Markov está compuesto por la 4-tupla (S, A, P_a, R_a) donde:

- **S** representa el estado del agente.

- \mathbf{A} es el conjunto de acciones que puede realizar el agente. A_s denota las acciones que puede realizar el agente desde un estado s .
- $P_a(s, s') = Pr(s_{t+1} = s' \mid s_t = s, a_t = a)$. Partiendo de un estado s , P_a representa la probabilidad de pasar al estado s' tomando la acción a .
- $R_a(s, s')$ denota la recompensa inmediata que recibiría el agente al realizar la transición de s a s' mediante la acción a .

Estos procesos cumplen la propiedad de Markov, es decir, que el pasado no influye en el agente, lo único relevante es el estado actual.

El problema principal de los MDP es encontrar la secuencia de acciones que debe realizar el agente para maximizar la recompensa a largo plazo, es decir, encontrar la política π óptima, que permita maximizar la recompensa. Una vez encontrada la política π óptima el problema se reduce a una cadena de Markov, dado que la acción a a realizar en un estado s viene completamente definida por el estado s y la probabilidad P_a .

La política π óptima es aquella que maximice la recompensa acumulada, es decir, la suma decontada de las recompensas instantáneas percibidas por el entorno:

$$\sum_{t_0}^{\infty} \gamma^t R_{a_t}(s_t, s_{t+1}) \quad \text{las acciones } a_t \text{ vienen dadas por } \pi(s_t) \quad (3.12)$$

donde γ es el factor de descuento, el cual debe cumplir $0 \leq \gamma \leq 1$, cuanto mayor sea este factor menos importante es la recompensa inmediata.

En los casos en los las probabilidades P_a o las recompensas R_a no se conocen a priori, es necesario emplear técnicas de aprendizaje por refuerzo para obtener esa política.

En estos problemas es útil definir el Q-valor

$$Q(s, a) = \sum_{s'} P_a(s, s') (R_a(s, s') + \gamma V(s')) \quad (3.13)$$

3.3.1. DQN

3.3.2. DDPG

3.3.3. TRPO

3.3.4. PPO

Hardware

Con el ánimo de tener una plataforma real sobre la que probar el rendimiento de los algoritmos de control diseñados, se ha diseñado y construido un cuadrirrotor *ad hoc* para este propósito.

Un cuadricóptero convencional cuenta con: un chasis o cuadro que lo sustenta, cuatro motores y la electrónica necesaria para controlarlos, una controladora de vuelo que lo comanda y baterías que le proporcionan energía.

A continuación se detallará como son las distintas partes físicas del dron que se ha fabricado.

4.1. Cuadro

El *frame* está compuesto por perfiles de aluminio y piezas de PLA fabricadas mediante impresión 3D de diseño propio. La estructura básica está formada por 5 conjuntos de piezas distintos:

- **Portamotores:** son las piezas donde se alojan los motores. Para conseguir una buena fijación los motores se atornillan a los portamotores empleando 4 tornillos dispuestos según los vértices de un rombo.

[Imagen](#)

- **Brazos:** se encargan de unir los portamotores con el *núcleo* de la estructura. En este diseño, los brazos consisten en perfiles de aluminio de sección cuadrada de 8mm de lado.
- **Núcleo:** Es la pieza principal del diseño, en la que se anclan el resto de las partes y donde se alojan los componentes electrónicos. Esta pieza sustenta los brazos y el porta-baterías de la aeronave. Cuenta con agujeros a medida para poder situar el autopiloto y los variadores.

[Imagen](#)

- **Separadores:** su propósito es mantener unidos el *núcleo* y el porta-baterías manteniendo una separación fija entre ellas.

[Imagen](#)

- **Porta-baterías:** Es la parte inferior del cuadricóptero. En ella se apoya la batería Li-Po que alimenta al dron y se mantiene anclada durante el vuelo. Además posee unas protuberancias cuya función se asemejaría a las de un tren de aterrizaje.

[Imagen](#)

4.2. Motores y hélices

El dron cuenta con 4 motores sin escobillas (*brushless*) LHI MT2204 II de 2300KV con una tensión de alimentación entre 7.2 V y 11.1 V (2s -3s en una batería LiPo) y una corriente continua máxima de 16A.




Figura 4.1: Motores LHI MT2204 II empleados

Se ha estimado que el peso aproximado de la aeronave se encuentra entorno a los 800 gramos. La literatura recomienda que los motores que se escojan deben tener empuje suficiente para poder levantar el doble del peso de la aeronave. Observando la tabla de especificaciones de los motores, se observa que, la hélice HQ5040 proporciona empuje suficiente con un ratio empuje/potencia bastante elevado, como se puede observar en la fig. 4.2.

Motor type	The voltage (V)	Propeller size	current (A)	thrust (G)	power (W)	efficiency (G/W)	speed (RPM)
MT2204 II - 2300KV	8	HQ5040	4.9	210	39.2	5.4	13840
		HQ6045	8.2	320	65.6	4.9	11300
		6030 CF	6.4	240	51.2	4.7	11910
	12	5030 CF	7.5	310	90.0	3.4	20100
		6030 CF	11.5	440	138.0	3.2	16300
		HQ5040	8.4	390	100.8	3.9	19040
		HQ6045	13.2	530	158.4	3.3	14600
	14.8	HQ5040	10.7	510	158.4	3.2	22180
		HQ6045	15.7	620	232.4	2.7	16100

Figura 4.2: Tabla de especificaciones motor MT2204 II.

Es por esto que se han empleado hélices tripala HQ5040 de policarbonato y fibra de vidrio (fig. 4.3).

4.3. Variadores (ESC)

Los motores que se han escogido son trifásicos, es decir, se alimentan con 3 corrientes alternas monofásicas de igual frecuencia y amplitud, desfasadas 120° eléctricos. Para obtener estas formas de ondas a partir de la corriente continua de las baterías, se utilizan los variadores.



Figura 4.3: Hélices tripala HQ5040

Un variador o *ESC* (*Electronic Speed Control*) es un circuito electrónico que se encarga de generar las ondas eléctricas necesarias para controlar y regular la velocidad de un motor eléctrico. Cuenta con un microcontrolador, el cual se encarga de conmutar los interruptores de potencia, con el ánimo de alimentar las distintas fases del motor de forma sincronizada, haciendo que gire a la velocidad deseada, véase la fig. 4.4.

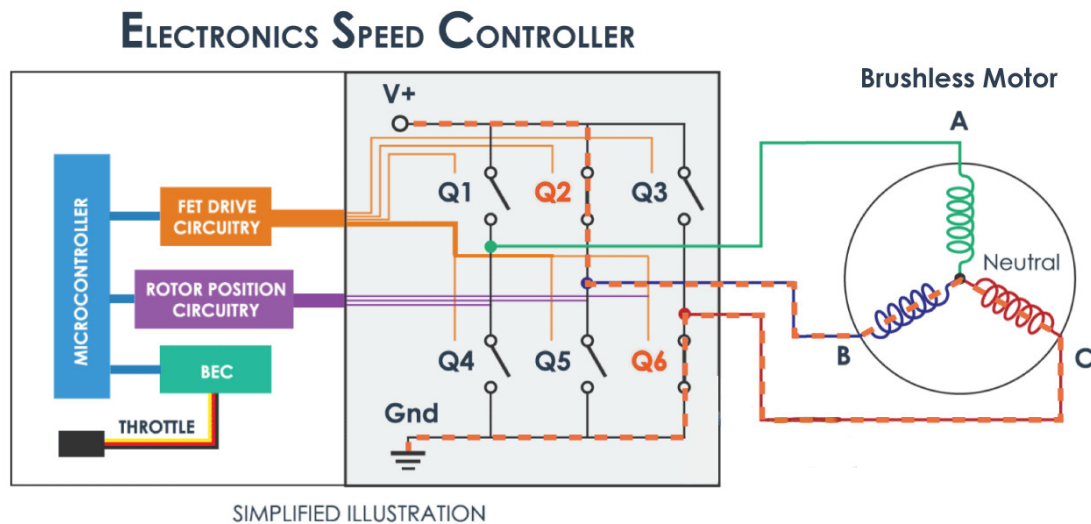


Figura 4.4: Funcionamiento ESC (www.howtomechatronics.com)

Para el cuadricóptero se ha optado por emplear un variador BLHeli Multistar Race (fig. 4.5) que integra 4 variadores en uno, es decir se pueden alimentar 4 motores trifasicos con él. Estos variadores soportan una corriente de hasta 30 A cada uno.

4.4. Baterías

Para alimentar al dron, se han elegido baterías tipo LiPo por su alta tasa de descarga (la batería que se ha escogido es capaz de entregar hasta 130 A) y la su estabilidad en la tensión mientras están cargadas.




Figura 4.5: ESC Multistar Race 4 in 1 30A BLHeli empleado




Figura 4.6: Curva típica de descarga de una batería LiPo (fuente: ProtoTalk.net)

4.5. Autopiloto

En los drones, el sistema que se encarga de estabilizar al cuadricóptero y hacerlo pilotable se denomina la controladora de vuelo o el Autopiloto. Existe una gran variedad de controladoras en el mercado, pero para este trabajo se ha diseñado una controladora propia con el fin de poder tener acceso a todos los sensores y a implementar el algoritmo de control de forma óptima. El autopiloto consta de 3 partes diferenciadas: la electrónica de potencia, el microcontrolador y los sensores. A continuación [se tratará](#) sobre estas partes con más detalle.

[Estaría bien un par de imágenes de la PCB \(anverso y reverso\)](#)




Figura 4.7: Autopiloto CaRL (*Cuadcopter with autopilot based on Reinforcement Learning*).

4.5.1. Fase de Potencia

Con el fin de poder gestionar la potencia entregada por las baterías a la placa y a los motores se ha diseñado una etapa de potencia en la que se debe mencionar dos partes: el interruptor de potencia y el regulador a 3.3 Voltios.

Interruptor de potencia

Los motores del dron pueden llegar a consumir 12 Amperios cada uno, lo que los cuatro motores pueden llegar a consumir 48 Amperios. Un interruptor con tamaño reducido no puede manejar tanta corriente, por ello se ha empleado un transistor MOSFET de canal P por el que pueden circular hasta 100 Amperios, con el fin de abrir o cerrar el paso de corriente desde las baterías al resto de la placa. El MOSFET se controla con un interruptor de poca potencia entre drenador y puerta.

Cuando se cierra el interruptor se alimenta directamente al ESC y al regulador de tensión.

Regulador a 3.3V

La electrónica digital de la PCB se alimenta y emplea lógica a 3.3 Voltios, por lo que no la podemos conectar a las baterías de 11.1 Voltios. Para adecuar la tensión se ha escogido un regulador Step-down de tipo Buck (Figura 4.8) ([¿explico como funciona un convertidor Buck?](#)). El circuito integrado que se encarga de conmutar la fuente es el chip AP3211.




Figura 4.8: Esquema de un convertidor Buck

4.5.2. El microcontrolador (ESP32)

El microcontrolador por el que se ha optado para este Autopiloto es el ESP32, un microcontrolador de doble núcleo con dos CPUs XTensaL6 con arquitectura Harvard [7]. El ESP32 tiene una frecuencia de reloj de hasta 240MHz ,y cuenta con una antena WiFi a 2,4 GHz y conexión Bluetooth 4.2 BLE [8]. Los motivos por los que se ha decidido emplear este microcontrolador son:

- Elevada frecuencia de procesamiento y dos núcleos de procesamiento.
- Antena WiFi incorporada.
- Bajo consumo de potencia.

Para poder programar el microcontrolador se utiliza un convertidor USB (Bus Serie Universal) a UART (Transmisor-Receptor Asíncrono Universal) que permite conectar por USB el microcontrolador para poder programarlo y hacer depuración utilizando comunicaciones Serial. El chip que realiza esta función es el CP2104.

4.5.3. Sensores

La principal fuente de información procedente del exterior que recibe una controladora de vuelo se la proporcionan las unidades de medición inercial (IMU). Las IMUs son dispositivos electrónicos que son capaces de medir aceleraciones, velocidades y detectar la orientación de un sistema. El principal problema de estos sensores es que sufren error acumulativo a la hora de estimar posición y velocidad. Para corregir este error acumulativo en los drones, se suelen fusionar estas medidas con otras provenientes de mediciones absolutas tales como GPS o Láser, aunque en este autopiloto únicamente emplearemos las medidas de las IMUs.

Otros sensores utilizados frecuentemente en los autopilotos son brújulas (se encuentran integrados en la IMU para corregir errores de orientación) y barómetros (para estimar la altitud a la que se encuentra el dron).

Nuestro autopiloto cuenta con dos IMUs de 9 Grados de Libertad y un barómetro para conseguir una mejor estimación del estado del cuadricóptero:

1. **BNO 055 (BOSCH):** El circuito integrado de Bosch es un sensor “inteligente” que incluye los sensores y la fusión de las lecturas de los distintos sensores en un

único componente. Este encapsulado cuenta con: un acelerómetro, un giróscopo y un magnetómetro triaxial. Además integra un microcontrolador de 32 bits en el que se ejecuta el algoritmo de fusión integrado. El sensor se encuentra en un encapsulado LGA de 28 pines con una huella (*footprint*) de $3,8 \times 5,2 \text{ mm}^2$.


Este sensor nos proporciona estimaciones del estado completo de la aeronave con una frecuencia de refresco de 100Hz.

2. **MPU 9250 (TDK InvenSense)**: El sensor inercial de TDK es un módulo multi-chip compuesto por un MPU6050 (Contiene un acelerómetro y un giróscopo triaxial con un *procesador digital de movimiento* (DMP)) y un AK8963 (un magnetómetro digital triaxial). El sensor posee un encapsulado QFN de $3 \times 3 \times 1 \text{ mm}$ con 24 pines.


Este dispositivo nos proporciona medidas del acelerómetro y el giróscopo a una frecuencia superior al BNO055 pero con una estimación peor de los ángulos que el dispositivo de BOSCH.

3. **BMP388 (BOSCH)**: El BMP388 es un barómetro digital de 24 bits con bajo consumo y bajo ruido. Se encuentra en un encapsulado LGA de 10 pines de dimensiones $2 \times 2 \times 0,75 \text{ mm}^3$.

Aunque el autopiloto cuenta con este sensor, éste no se ha utilizado en este trabajo debido a que no se tiene en cuenta la altitud en los controladores.



(a) Sensor BNO055



(b) Sensor BMP388

4.6. Banco de pruebas

Para poder realizar la experimentación real de forma segura, se han diseñado distintas estructuras para poder sujetar al cuadricóptero permitiéndole rotar con distintos grados de libertad (GdL) en función de la estructura. Estas uniones han permitido poder probar distintos controladores de forma segura y controlada.


Se pueden distinguir 2 tipos de estructuras en función de sus grados de libertad:

- **Rótulas con 1 único grado de libertad**: Para las primeras pruebas de los reguladores es fundamental poder descomponer el control en problemas más sencillos, en este caso permitiendo al sistema rotar en 1 grado de libertad. Se han construido 2 versiones de la misma rótula, una permite el movimiento en Pitch y la otra lo permite en Roll. Esto permite desacoplar los bucles de control y poder probar distintos algoritmos de control.

Estas uniones son sencillas y robustas lo que nos da seguridad a la hora de poder probar y ajustar los reguladores. Las restricciones de movimiento de estas uniones permiten rotaciones de $\pm 60^\circ$ en el ángulo permitido.



(a) Motores LHI MT2204 II empleados




(b) ESC Multistar Race 4 in 1 30A BLHeli empleado


- **Rótula con múltiples grados de libertad:** Después de conseguir estabilizar al cuadricóptero en pitch y en roll de forma individual la siguiente aproximación consiste en emplear rotulas con 3 GdL. Sobre estas uniones también se han realizado 2 versiones. La primera consta de una única rotula con sus 3 grados de libertad con restricciones de movimiento de:

$$\begin{aligned} -60^\circ \leq \varphi \leq 60^\circ & \quad \text{Roll} \\ -60^\circ \leq \theta \leq 60^\circ & \quad \text{Pitch} \\ -180^\circ \leq \psi \leq 180^\circ & \quad \text{Yaw} \end{aligned}$$

La segunda consta de acoplar 2 juntas esféricas como las anteriores una a continuación de la otra, lo que permite, además de disminuir las restricciones de movimiento en las rotaciones, pequeños desplazamientos en el espacio tridimensional.



(a) Motores LHI MT2204 II empleados



(b) ESC Multistar Race 4 in 1 30A BLHeli empleado

imagen rotulas y/o CAD

Software

Durante el transcurso de este trabajo se ha dividido el desarrollo del software en varias partes, en las cuales se profundizará a continuación.

5.1. Software del Autopiloto

El autopiloto es la parte del multirrotor que se encarga de generar las acciones de control o comandos, que permitan que el dron llegue a un determinado estado. Para generar esas acciones de control, el autopiloto estima el estado de la aeronave en cada instante mediante las lecturas de las IMUs y en función del estado genera las acciones de control pertinentes para mantener la estabilidad de la aeronave. Además el autopiloto que se ha desarrollado cuenta con un interfaz WiFi, por lo que permite enviar y recibir datos del autopiloto a una estación de tierra. A continuación se profundizará en como se han llevado a cabo estas tareas.

5.1.1. Estimación del Estado

Para estimar el estado, el autopiloto toma las medidas procedentes de las 2 IMUs a través del protocolo I2C con una frecuencia de comunicación de 400KHz. Las lecturas del BNO055 proporcionan un estado completo de la aeronave con una frecuencia de refresco de 100Hz. Sin embargo, el MPU9250 nos proporciona medidas relativas a las velocidades angulares y aceleraciones lineales con una tasa de refresco más elevada. Es por esto que se han empleado ambos sensores para conseguir el estado deseado con la mayor precisión y menor tasa de refresco posible.

Con este método se consigue estimar el estado deseado:

$$S_t = \left(\underbrace{\varphi, \theta, \psi}_{\text{BNO}}, \underbrace{\dot{\varphi}, \dot{\theta}, \dot{\psi}}_{\text{MPU}} \right) \quad (5.1)$$

consiguiendo minimizar la deriva de la estimación, empleando las lecturas muy estables del BNO055, sin perder la reactividad de las medidas que proporciona el MPU9250.

5.1.2. Interfaz WiFi

Con la intención de poder transmitir datos entre el autopiloto y la estación de tierra se ha diseñado un sencillo protocolo de comunicación WiFi basado en el envío de paquetes de tamaño fijo. El ESP32 cuenta con un sistema operativo en tiempo real (RTOS) el cual se encarga de mantener activa las comunicación WiFi de forma transparente al usuario. La estructura de los paquetes es la siguiente:

- **Autopiloto** \rightarrow **Estación**: Este paquete contiene 6 datos de tipo *float* (32-bits). Se emplea para enviar la estimación del estado a la aeronave en tiempo real. Esto se emplea para tanto monitorización del desempeño de los algoritmos, como para poder cerrar el bucle de control en la estación base y enviar las acciones de control a la aeronave posteriormente.
- **Autopiloto** \leftarrow **Estación**: Este paquete contiene 4 datos de tipo *float* (32-bits) y un dato de tipo *byte*. El dato de tipo *byte* se emplea para controlar el modo de funcionamiento de la aeronave, mientras que los otros 4 datos tienen distintos usos en función del modo:
 - **MODO 0** (Desarmado): La aeronave se encuentra “desarmada” por lo que los motores no reciben acciones de control. En este modo los demás datos del paquete son irrelevantes.
 - **MODO 1** (*Off-board*): Las acciones de control son emitidas por la estación de tierra, es decir, la aeronave envía la estimación del estado al ordenador y envía el comando recibido a los variadores. En este modo los datos de tipo *float* del paquete representan los comandos de los motores.
 - **MODO 2** (*On-board*): El algoritmo de control se ejecuta en la aeronave y se generan las señales de control necesarias a una frecuencia fijada previamente. En el caso de los controladores PID a bordo, los valores de los 4 datos del paquete permiten variar los valores de las constantes del regulador en tiempo real, lo que facilita el ajuste de las mismas.

5.1.3. Generacion de comandos *on-board*

Para poder maximizar la frecuencia del algoritmo de control y permitir el control de la aeronave sin necesidad de una estación de tierra, los algoritmos de control validados en la simulación se pueden implementar directamente en el autopiloto, fijando previamente la frecuencia a la que se desea que se ejecute el algoritmo. [actualizar en el momento](#) En este trabajo se han implementado a bordo dos algoritmos de control distintos: un regulador PID clásico y un regulador PID en cascada.

5.2. Software de la estación

La estación base se ha empleado tanto como para la simulación del entorno, permitiendo diseñar y probar algoritmos de control de forma segura, como para monitorizar los rendimientos de estos algoritmos o incluso, aprovechando la mayor capacidad computacional de estas estaciones, ejecutar los algoritmos de control y aprendizaje por refuerzo en estas. A continuación se profundizará con más detalle en la implementación de estas herramientas.

5.2.1. Entorno de simulación

En cualquier proyecto de robótica es conveniente contar con un entorno de simulación que permita realizar pruebas en distintas situación de forma sencilla y rápida, sin necesidad de tener ni modelo real, ni el entorno concreto en el que quieras probar tu robot. Cuando se trabaja con drones, la simulación pasa de ser conveniente a ser muy necesaria. Ésto es

debido a la peligrosidad intrínseca de estas aeronaves, ya que, cuentan con hélices afiladas que giran a gran velocidad.

Debido a la naturaleza del aprendizaje por refuerzo, este requiere de la interacción de un agente con un entorno para que el agente aprenda que acciones son las que debe tomar en cada estado. Esto significa que al comienzo del entrenamiento el agente realiza acciones aleatorias para poder explorar cuales son las que le proporcionan una recompensa mayor.

Debido a esta forma de explorar, el agente requiere de una gran cantidad de pruebas, de ensayo y error, hasta que consigue aprender, por lo que no es conveniente realizar todas estas iteraciones en un modelo real.

Por estas razones se necesita de un entorno de simulación para poder validar los algoritmos y poder generar modelos entrenados en simulación sin deteriorar el equipo real. Además el entorno en simulación te permite entrenar distintos agentes simultáneamente y reducir los tiempos de entrenamiento.

Para el entorno de simulación nos hemos basado en Gym [citar](#), una librería escrita en Python y desarrollada por la compañía OpenAI, que permite desarrollar y comparar algoritmos de aprendizaje por refuerzo. Esta librería te permite generar un entorno con el cual interactúe el agente, sin importar la implementación de éste, permitiendo comparar el rendimiento de distintos agentes sobre el mismo entorno. [IMAGEN GYM](#)

[revisar](#) Como entorno de simulación se ha partido de GymFC, desarrollado por William Koch et al. [5]. Este entorno de simulación utiliza Gazebo 9, un entorno de simulación 3D de código abierto ampliamente utilizado en el campo de la robótica. En este entorno se simula el comportamiento de un multirrotor, concretamente el de un modelo del cuadricóptero IRIS. [imagen GYMFC](#)

Para acercar la simulación a la configuración de los experimentos que se realizarían posteriormente en la plataforma real, se han realizado algunas modificaciones sobre el modelo predeterminado de la aeronave:

1. Se ha modificado la forma de anclaje del dron. Originalmente el dron se encontraba anclado entorno a una articulación situada en su centro de gravedad. Esto permitía que el peso de la aeronave apenas tuviera influencia a la hora de rotar la aeronave, todo el peso estaba sustentado por la articulación, lo cual no se asemeja con los bancos de pruebas que se han diseñado. En estos bancos de prueba el anclaje se encuentra desplazado con respecto al centro de gravedad, por lo que cuanto mayor sea el valor de los ángulos φ y θ mayor es la influencia del peso en el par necesario para estabilizar la aeronave. Es por esto que se ha desplazado la articulación del centro de gravedad y se ha conectado a la aeronave mediante una unión rígida, asemejando así el entorno de simulación al entorno de pruebas real.
2. Se ha modificado parámetros dinámicos de la aeronave. Los parámetros que mayor discrepancia tenían entre la simulación y el mundo real eran principalmente los parámetros inerciales. Tanto la masa como los momentos de inercia del cuadricóptero eran mucho inferiores a los de la aeronave real. Esto se manifestaba principalmente cuando al hacer pruebas con los algoritmos PID el comportamiento simulado no se parecía con el real, por ejemplo en simulación un regulador P era capaz de estabilizar al sistema, mientras que en la realidad un regulador P era inestable de por sí y requería de las acciones derivativa e integral para conseguir estabilizarlo.

5.2.2. Agente (generación de comandos)

Siguiendo con la terminología del aprendizaje por refuerzo se va a denominar agente al encargado de generar las acciones de control. En el caso de los reguladores PID clásicos el agente hace la función de los reguladores.

Para probar distintos agentes con distintos algoritmos se han empleado la implementación de los algoritmos *state of the art*, del repositorio de GitHub *Stable-Baselines* [9]. Inicialmente se comenzó empleando las *Baselines* de OpenAI [10] pero se decidió cambiar a las *Stable Baselines* por la limpieza del código y la facilidad para realizar experimentos con diversos algoritmos e hiperparámetros.

[¿hablo un poco sobre transfer learning?](#)

5.2.3. Interfaz Estación-Autopiloto

Para las pruebas reales se han empleado

Ademas se ha empleado ROS Melodic para conectar este entorno con el dron real.

5.3. Descripción del equipo

Para el desarrollo del trabajo se ha empleado un portatil MSI-GE62 empleando Windows 10 para el desarrollo CAD y Ubuntu 18.04 LTS para el resto de las tareas. El equipo cuenta con 16GB de RAM DDR4, un procesador Intel i7-6700HQ de 8 núcleos a 2.60GHz y una GPU GeForce GTX 970M con 3GB de memoria dedicada.

Metodología (Problem Formulation)

El objetivo del trabajo es estabilizar un UAV usando algoritmos de control basados en una red neuronal entrenada empleando algoritmos de aprendizaje automático. Los principales componentes que intervienen en el agente son el estado, las acciones y la recompensa, para cada problema hay un conjunto de estados, acciones y funciones de recompensa que pueden llevar a que el agente aprenda.

6.1. Diseño del estado

El autopiloto cuenta con 2 IMUs para poder obtener datos sobre su estado. Se quiere estabilizar el dron en una orientación concreta, por lo tanto el estado que se ha diseñado consta de 6 parámetros:

$$S = (\varphi, \theta, \psi, \dot{\varphi}, \dot{\theta}, \dot{\psi}) \quad \varphi, \theta, \psi, \dot{\varphi}, \dot{\theta}, \dot{\psi} \in [-1, 1] \quad (6.1)$$

Siendo φ, θ y ψ los ángulos de alabeo (*roll*), cabeceo (*pitch*) y guiñada (*yaw*) del dron y $\dot{\varphi}, \dot{\theta}$ y $\dot{\psi}$ sus respectivas velocidades. Para favorecer la convergencia del aprendizaje, se ha normalizado el estado para que todas sus componentes estén comprendidas dentro del intervalo $[-1, 1]$.

Los ángulos proporcionan información sobre el estado actual y la velocidad angular sobre los estados pasados, es decir, proporciona cierta información temporal.

Para obtener la estimación de orientación se han fusionado las medidas de las 2 IMUs del autopiloto utilizando un filtro complementario, para así conseguir una buena estimación estática junto con una buena respuesta dinámica.

6.2. Diseño de las acciones

Al trabajar con un quadricóptero podemos actuar sobre la potencia que se le entrega a los motores, por lo que cada acción que realice el agente constará de 4 campos:

$$A = (T_1, T_2, T_3, T_4) \quad T_i \in [-1, 1] \quad (6.2)$$

Siendo T_i la potencia (*Thrust*) normalizada entregada a cada motor. Un valor de $T_1 = -1$ significa que el motor 1 estaría girando a la mínima potencia permitida y un valor de $T_1 = 1$ corresponde a que el motor 1 estaría girando a la máxima potencia.

completar con la transformacion del mundo
-1,1 al mundo 1000,2200 μS

6.3. Diseño de la función de recompensa

La función de recompensa rige la forma en la que la red va a configurar sus pesos, por lo tanto, cómo se va a comportar el agente en un estado determinado. Para conseguir que el agente responda de la forma deseada se han probado una gran variedad de funciones de *reward*, optando finalmente por:

$$R_t = \left(1 - \frac{|\varphi| + |\theta| + |\psi|}{3}\right)^3 \quad (6.3)$$

Con esta funcion de recompensa [BLA BLA BLA](#)

Experimentos

Pa

Discusión

Conclusiones y trabajo futuro

Índice de figuras

1.1	Esquema cuadirrotor en X	2
1.2	Autopiloto comercial Pixhawk 4	3
4.1	Motores LHI MT2204 II empleados	11
4.2	Tabla de especificaciones motor MT2204 II.	11
4.3	Hélices tripala HQ5040	12
4.4	Funcionamiento ESC (www.howtomechatronics.com)	12
4.5	ESC Multistar Race 4 in 1 30A BLHeli empleado	13
4.6	Curva típica de descarga de una batería LiPo (fuente: ProtoTalk.net)	13
4.7	Autopiloto CaRL (<i>Cuadcopter with autopilot based on Reinforcement Learning</i>).	14
4.8	Esquema de un convertidor Buck	15

Índice de tablas

Bibliografía

- [1] H. J. Kim, M. I. Jordan, S. Sastry, and A. Y. Ng, “Autonomous helicopter flight via reinforcement learning,” in *Advances in neural information processing systems*, 2004, pp. 799–806.
- [2] A. Y. Ng, A. Coates, M. Diel, V. Ganapathi, J. Schulte, B. Tse, E. Berger, and E. Liang, “Autonomous inverted helicopter flight via reinforcement learning,” in *Experimental robotics IX*. Springer, 2006, pp. 363–372.
- [3] T. Dierks and S. Jagannathan, “Output feedback control of a quadrotor uav using neural networks,” *IEEE transactions on neural networks*, vol. 21, no. 1, pp. 50–66, 2010.
- [4] J. Hwangbo, I. Sa, R. Siegwart, and M. Hutter, “Control of a quadrotor with reinforcement learning,” *IEEE Robotics and Automation Letters*, vol. 2, no. 4, pp. 2096–2103, 2017.
- [5] W. Koch, R. Mancuso, R. West, and A. Bestavros, “Reinforcement learning for uav attitude control,” *ACM Transactions on Cyber-Physical Systems*, vol. 3, no. 2, p. 22, 2019.
- [6] R. S. Sutton and A. G. Barto, *Reinforcement learning: An introduction*. MIT press, 2018.
- [7] “Esp32 technical reference manual,” Espressif Systems, 2018. [Online]. Available: https://www.espressif.com/sites/default/files/documentation/esp32_technical_reference_manual_en.pdf
- [8] “Esp32 datasheet,” Espressif Systems, 2019. [Online]. Available: https://www.espressif.com/sites/default/files/documentation/esp32_datasheet_en.pdf
- [9] A. Hill, A. Raffin, M. Ernestus, A. Gleave, R. Traore, P. Dhariwal, C. Hesse, O. Klimov, A. Nichol, M. Plappert, A. Radford, J. Schulman, S. Sidor, and Y. Wu, “Stable baselines,” <https://github.com/hill-a/stable-baselines>, 2018.
- [10] P. Dhariwal, C. Hesse, O. Klimov, A. Nichol, M. Plappert, A. Radford, J. Schulman, S. Sidor, Y. Wu, and P. Zhokhov, “Openai baselines,” <https://github.com/openai/baselines>, 2017.